

Machine Learning II — ADIF84

Lab 1 — Classification des districts scolaires

Prédire l'engagement dans les bus scolaires électriques (ESB) par forêts aléatoires

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Projet : tableau de bord des autobus scolaires électriques aux États-Unis (WRI / ESB Initiative)

1. Compréhension du problème métier

Objectif business

Identifier les districts scolaires ayant une forte probabilité de **s'engager dans l'adoption de bus électriques**, à partir de leurs caractéristiques socio-économiques, environnementales et institutionnelles.

Question à laquelle le modèle répond :

« Ce district va-t-il s'engager dans l'électrification de sa flotte de bus scolaires ? »

Variable cible — oa. Has committed ESBs?

1 = district engagé

0 = district non engagé

Type de tâche

Classification binaire supervisée

On apprend un modèle reliant les attributs prédictifs à un attribut-classe connu, puis on l'évalue sur des données non vues.

Apprentissage supervisé : la « bonne réponse » (engagé / non) est connue à l'entraînement.

Intérêt métier : un commercial / décideur peut prioriser les districts à fort potentiel pour cibler ses démarches (subventions, offres, accompagnement).

2. Compréhension des données

19 516

districts scolaires

91

colonnes dans la source

7,81 %

de districts engagés

Source : Dataset of U.S. Electric School Bus Adoption (World Resources Institute / ESB Initiative), feuille « District-level data ». Chaque ligne = un district scolaire.

Un jeu de données fortement déséquilibré

Seulement 7,81 % de districts engagés. Conséquence directe : l'accuracy devient trompeuse (un modèle qui prédit toujours « non engagé » atteindrait ≈ 92 % d'accuracy sans aucune utilité). On évaluera donc le modèle sur le **F1-score de la classe positive**, et on corrigera le déséquilibre par SMOTE (voir étape 3).

→ Exploration menée : distribution de la cible, taux d'engagement par région/zone, corrélations entre variables numériques.

3. Préparation des données d'entraînement

1

Découpage train / test

80 / 20 avec stratify : conserve la proportion de classes dans les deux sous-ensembles (crucial vu le déséquilibre).

2

Encodage catégoriel

TargetEncoder : chaque modalité remplacée par son taux d'engagement moyen. Évite l'explosion dimensionnelle du one-hot.

3

Mise à l'échelle

StandardScaler sur les variables numériques pour les ramener à une échelle comparable.

4

Gestion du déséquilibre


SMOTE appliqué UNIQUEMENT sur le train (via Pipeline imblearn) : génère des exemples synthétiques sans fuite de données.

Sélection de variables anti-fuite (data leakage)

Exclusion du bloc 3* (ESB committed/operating/delivered...) qui décrit l'engagement déjà réalisé = la cible déguisée. **Enrichissement par 3 variables à fort signal** : 4c. Nb d'écoles ($r=+0.24$), 5b. % non-white/Hispanic ($r=+0.18$), 5o. EPA 2022 prioritized (subvention fédérale).

4a. Choix du modèle — comparaison

Trois algorithmes comparés sur le même pipeline (prétraitement + SMOTE), validation croisée 5 plis, métrique F1 (classe positive)



Pourquoi comparer plusieurs modèles ?

Random Forest : bagging d'arbres, robuste, fournit l'importance des variables (interprétable).

Gradient Boosting : boosting séquentiel, souvent plus précis.

XGBoost : boosting optimisé, référence sur données tabulaires.

Protocole identique pour les 3 modèles

Même pipeline (prétraitement + SMOTE), même validation croisée 5 plis, même métrique F1 — pour garantir la comparabilité des résultats.

4b. Réglage fin (GridSearchCV)

On règle finement les DEUX meilleurs (RF & GB) par GridSearchCV — puis on retient le plus performant après optimisation

Modèle	F1 par défaut	F1 après réglage	Rang final
Random Forest	0.339	0.370	1 ^{er} ★
Gradient Boosting	0.354	0.368	2 ^e

Hyperparamètres testés (RF)

- n_estimators : 100 / 200 / 300
 - max_depth : 8 / 12 / 16 / None
 - min_samples_leaf : 1 / 5
- 24 combinaisons × 5 plis = 120 entraînements

Effet du réglage

Par défaut, Gradient Boosting devançait Random Forest (0,354 vs 0,339).
Après GridSearchCV, Random Forest passe en tête à 0,370.
Le classement des modèles dépend donc du réglage d'hyperparamètres : une comparaison par défaut ne suffit pas.

Pourquoi optimiser le F1 et non l'accuracy ?

Avec ≈ 8 % de positifs, l'accuracy est trompeuse : un modèle constant « non engagé » atteindrait ≈ 92 % d'accuracy sans aucune utilité. Le **F1 équilibre précision et rappel** sur la classe qui nous intéresse : les districts engagés. SMOTE est ré-appliqué dans chaque pli de validation croisée → aucune fuite de données vers le test.

4c. Résultats du modèle final

0.813

AUC-ROC

bonne capacité de discrimination

0.40

F1 (classe engagé)


precision 0.43 · recall 0.37

0,91

accuracy globale

sur 3 904 districts de test

Importance des variables (Random Forest)



Interprétation

La taille du district (nombre d'écoles, d'élèves, de bus) domine l'importance des variables : plus un district est grand, plus il a de moyens pour s'engager.

Les facteurs hors dataset (volonté politique locale, budgets d'État, programmes spécifiques) ne sont pas pris en compte et limitent le pouvoir prédictif du modèle.

Conclusion & pistes

Démarche validée

- Sélection de variables justifiée et anti-fuite
- Préparation robuste (split stratifié, SMOTE sans fuite)
- Comparaison de 3 modèles puis réglage des 2 finalistes
- Modèle retenu : Random Forest (F1 CV 0.370, AUC 0.81)

Pistes d'amélioration (TRL / B206)

- Ajuster le seuil de décision selon le coût métier d'un faux négatif
- Enrichir avec d'autres variables (programmes d'État)
- Tester un ré-équilibrage par pondération de classe

Modèle final : Random Forest

AUC-ROC = 0,81 · F1 (classe engagé) = 0,40 · accuracy = 0,91