

Machine Learning II — ADIF84

Lab 1 — Classification des districts scolaires

Prédire l'engagement dans les bus scolaires électriques (ESB) par forêts aléatoires

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Projet : tableau de bord des autobus scolaires électriques aux États-Unis (WRI / ESB Initiative)

Introduction — Contexte du projet

26 M

élèves américains
prennent le bus scolaire
chaque matin

480 000

bus scolaires
en circulation
(majoritairement diesel)

19 516

districts scolaires
recensés dans
le dataset WRI

Ces bus circulent souvent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Depuis quelques années, des programmes fédéraux et des subventions accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

Source de données

Dataset of U.S. Electric School Bus Adoption

World Resources Institute / ESB Initiative

Feuille « District-level data »

Chaque ligne = un district scolaire

91 colonnes — socio-économiques,
environnementales, géographiques

1. Compréhension du problème métier

Ce TP — Classification supervisée par forêts aléatoires

« Ce district va-t-il s'engager dans l'électrification de sa flotte de bus scolaires ? »

Objectif business

Identifier les districts à fort potentiel d'engagement ESB, à partir de leurs caractéristiques socio-économiques, environnementales et institutionnelles.

Type de tâche

Classification binaire supervisée.
Variable cible : 1 = engagé / 0 = non engagé.
Modèle retenu : Forêt Aléatoire.
Deux défis : déséquilibre + data leakage.

Intérêt métier

Un commercial peut prioriser les districts à fort potentiel pour cibler sa démarche : subventions, offres, accompagnement.

Données : 19 516 districts scolaires — source WRI. Seulement 7,8 % de districts engagés → jeu fortement déséquilibré.

1. Compréhension du problème métier

Objectif business

Identifier les districts scolaires ayant une forte probabilité de **s'engager dans l'adoption de bus électriques**, à partir de leurs caractéristiques socio-économiques, environnementales et institutionnelles.

Question à laquelle le modèle répond :

« Ce district va-t-il s'engager dans l'électrification de sa flotte de bus scolaires ? »

Variable cible — 0a. Has committed ESBs?

1 = district engagé

0 = district non engagé

Type de tâche

Classification binaire supervisée

On apprend un modèle reliant les attributs prédictifs à un attribut-classe connu, puis on l'évalue sur des données non vues.

Apprentissage supervisé : la « bonne réponse » (engagé / non) est connue à l'entraînement.

Intérêt métier : un commercial / décideur peut prioriser les districts à fort potentiel pour cibler ses démarches (subventions, offres, accompagnement).

2. Compréhension des données

19 516

districts scolaires

91

colonnes dans la source

7,81 %

de districts engagés

Source : Dataset of U.S. Electric School Bus Adoption (World Resources Institute / ESB Initiative), feuille « District-level data ». Chaque ligne = un district scolaire.

Un jeu de données fortement déséquilibré

Seulement 7,81 % de districts engagés. Conséquence directe : l'accuracy devient trompeuse (un modèle qui prédit toujours « non engagé » atteindrait ≈ 92 % d'accuracy sans aucune utilité). On évaluera donc le modèle sur le **F1-score de la classe positive**, et on corrigera le déséquilibre par SMOTE (voir étape 3).

→ Exploration menée : distribution de la cible, taux d'engagement par région/zone, corrélations entre variables numériques.

3. Préparation des données d'entraînement

1

Découpage train / test

80 / 20 avec stratify : conserve la proportion de classes dans les deux sous-ensembles (crucial vu le déséquilibre).

2

Encodage catégoriel

TargetEncoder : chaque modalité remplacée par son taux d'engagement moyen. Évite l'explosion dimensionnelle du one-hot.

3

Mise à l'échelle

StandardScaler sur les variables numériques pour les ramener à une échelle comparable.

4

Gestion du déséquilibre


SMOTE appliqué UNIQUEMENT sur le train (via Pipeline imblearn) : génère des exemples synthétiques sans fuite de données.

Sélection de variables anti-fuite (data leakage)

Exclusion du bloc 3* (ESB committed/operating/delivered...) qui décrit l'engagement déjà réalisé = la cible déguisée. **Enrichissement par 3 variables à fort signal** : 4c. Nb d'écoles ($r=+0.24$), 5b. % non-white/Hispanic ($r=+0.18$), 5o. EPA 2022 prioritized (subvention fédérale).

4a. Choix du modèle — comparaison

Trois algorithmes comparés sur le même pipeline (prétraitement + SMOTE), validation croisée 5 plis, métrique F1 (classe positive)



Pourquoi comparer plusieurs modèles ?

Random Forest : bagging d'arbres, robuste, fournit l'importance des variables (interprétable).

Gradient Boosting : boosting séquentiel, souvent plus précis.

XGBoost : boosting optimisé, référence sur données tabulaires.

Protocole identique pour les 3 modèles

Même pipeline (prétraitement + SMOTE), même validation croisée 5 plis, même métrique F1 — pour garantir la comparabilité des résultats.

4b. Réglage fin (GridSearchCV)

On règle finement les DEUX meilleurs (RF & GB) par GridSearchCV — puis on retient le plus performant après optimisation

Modèle	F1 par défaut	F1 après réglage	Rang final
Random Forest	0.339	0.370	1 ^{er} ★
Gradient Boosting	0.354	0.368	2 ^e

Hyperparamètres testés (RF)

- n_estimators : 100 / 200 / 300
 - max_depth : 8 / 12 / 16 / None
 - min_samples_leaf : 1 / 5
- 24 combinaisons × 5 plis = 120 entraînements

Effet du réglage

Par défaut, Gradient Boosting devançait Random Forest (0,354 vs 0,339).
Après GridSearchCV, Random Forest passe en tête à 0,370.
Le classement des modèles dépend donc du réglage d'hyperparamètres : une comparaison par défaut ne suffit pas.

Pourquoi optimiser le F1 et non l'accuracy ?

Avec ≈ 8 % de positifs, l'accuracy est trompeuse : un modèle constant « non engagé » atteindrait ≈ 92 % d'accuracy sans aucune utilité. Le **F1 équilibre précision et rappel** sur la classe qui nous intéresse : les districts engagés. SMOTE est ré-appliqué dans chaque pli de validation croisée → aucune fuite de données vers le test.

4c. Résultats du modèle final

0.813

AUC-ROC

bonne capacité de discrimination

0.40

F1 (classe engagé)


precision 0.43 • recall 0.37

0,91

accuracy globale

sur 3 904 districts de test

Importance des variables (Random Forest)



Interprétation

La taille du district (nombre d'écoles, d'élèves, de bus) domine l'importance des variables : plus un district est grand, plus il a de moyens pour s'engager.

Les facteurs hors dataset (volonté politique locale, budgets d'État, programmes spécifiques) ne sont pas pris en compte et limitent le pouvoir prédictif du modèle.

Conclusion & pistes

Démarche validée

- Sélection de variables justifiée et anti-fuite
- Préparation robuste (split stratifié, SMOTE sans fuite)
- Comparaison de 3 modèles puis réglage des 2 finalistes
- Modèle retenu : Random Forest (F1 CV 0.370, AUC 0.81)

Pistes d'amélioration (TRL / B206)

- Ajuster le seuil de décision selon le coût métier d'un faux négatif
- Enrichir avec d'autres variables (programmes d'État)
- Tester un ré-équilibrage par pondération de classe

Modèle final : Random Forest

AUC-ROC = 0,81 · F1 (classe engagé) = 0,40 · accuracy = 0,91