

Machine Learning II — ADIF84

Lab 2 — Segmentation des districts par K-means

Identifier des profils-types de districts engagés pour cibler une démarche commerciale

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Tâche non supervisée — clustering

1. Compréhension du problème métier

Objectif business

Identifier des **groupes (segments) de districts** parmi ceux déjà engagés dans les bus électriques, afin de mieux cibler une démarche commerciale / publicitaire.

Décideur visé : société de vente de bus électriques.

Question :

« Existe-t-il des profils-types de districts engagés, vers lesquels adapter un discours commercial distinct ? »

Type de tâche

Clustering — non supervisé

Pas de « bonne réponse » à prédire : on cherche une structure cachée dans les données (tâche descriptive).

4 variables socio-économiques

- % flotte électrique
- Nombre d'élèves (taille)
- % repas gratuits (précarité scolaire)
- % pauvreté

Exploitation commerciale : chaque segment appelle un discours distinct (extension de flotte, mise en avant des subventions, offres de volume...).

2. Compréhension des données

1 524

districts engagés (committed = yes)

4

variables retenues

22

valeurs aberrantes détectées

Détection de valeurs aberrantes

La variable « % flotte électrique » contenait des valeurs > 100 % (jusqu'à 2300 % !). Ce sont des erreurs de données. K-means étant très sensible aux valeurs extrêmes, elles fausseraient totalement le clustering. → Elles seront plafonnées à 100 % lors de la préparation.

Exploration menée

Taux de valeurs manquantes par variable (jusqu'à 19 % sur « % flotte électrique »), statistiques descriptives, et histogrammes des 4 variables — qui ont révélé les valeurs extrêmes ci-dessus.

3. Préparation des données d'entraînement

1

Correction des aberrants

« % flotte électrique » plafonné à 100 %. K-means minimise des distances au carré → un point aberrant accaparerait un cluster entier.

2

Imputation (médiane)

Valeurs manquantes remplacées par la médiane, robuste aux valeurs extrêmes (contrairement à la moyenne).

3

Standardisation

StandardScaler : indispensable car K-means repose sur des distances. Sans elle, « Nb élèves » (milliers) écraserait les % (0–1).

4

Export du jeu

Données préparées exportées en clustering.csv — livrable « fichier d'entraînement » demandé par le sujet.


Deux limites assumées

19 % de NA sur « % flotte électrique » imputés par la médiane (variable à interpréter avec prudence). On conserve les valeurs extrêmes légitimes (méga-districts comme NYC, LA) : ce ne sont pas des erreurs mais un vrai segment « très grands districts ».


4a. Choix du nombre de clusters K

Deux critères complémentaires pour choisir K : la méthode du coude (inertie) et le score de silhouette.

Méthode du coude — inertie selon K



Silhouette selon K — maximum à K = 4



Lecture des deux critères

Coude : la décroissance de l'inertie ralentit nettement après $K = 4$ (le « coude »). **Silhouette** : maximum atteint à $K = 4$ (0,327).
Les deux critères convergent vers $K = 4$. Affiné ensuite par grille $K \times \text{init}$ (14 combinaisons), puis validé par l'interprétation des profils.

4b. K=3 vs K=4 : comparaison des profils

Comparaison directe des profils obtenus avec K=3 et K=4 (z-scores : positif = au-dessus de la moyenne).

K = 3 · silhouette = 0,294

Segment	Taille	Caractéristique
Défavorisés	689	Forte pauvreté / repas gratuits
Aisés	814	Faible pauvreté
Très grands districts	21	Nb élèves très élevé (+6,8σ)

K = 4 · silhouette = 0,327

Segment	Taille	Caractéristique
Pionniers	165	Forte électrification (+2,35σ)
Aisés	734	Faible pauvreté
Défavorisés	604	Forte pauvreté / repas gratuits
Très grands districts	21	Nb élèves très élevé (+6,8σ)



K = 4 retenu

Meilleure silhouette : 0,327 contre 0,294 pour K=3. **4 profils distincts et exploitables** : K=4 isole un segment « Pionniers » (165 districts à forte électrification) que K=3 fusionnait avec les Défavorisés.

Rôle clé du nettoyage : sans correction des valeurs aberrantes (% électrique > 100 %), K=4 créait un cluster d'un seul district — inutile. Après plafonnement à 100 %, ce 4^e segment devient un vrai groupe commercial pertinent.

4c. Comparaison avec un autre algorithme

Comparaison de K-means à un autre algorithme de clustering : l'agglomératif avec critère de Ward.



L'algorithme agglomératif en bref

- Chaque district démarre seul (1524 clusters).
- À chaque étape, on fusionne les 2 clusters les plus proches.
- On répète jusqu'à obtenir le nombre voulu (ici $K = 4$).

Critère de Ward = minimise la variance interne (analogue de K-means).

Conclusion

K-means bat l'agglomératif sur les deux métriques (silhouette et Davies-Bouldin).

Les deux algorithmes retrouvent la même structure en 4 groupes : la segmentation est robuste, ce n'est pas un artefact d'une méthode.

4. Modèle final retenu

K = 4

clusters retenus

0,327

silhouette globale

4

segments métier actionnables

Les 4 segments et leur ciblage commercial

- **Pionniers** : proposer l'extension de flotte
- **Très grands districts** : offres de volume
- **Défavorisés** : mettre en avant les subventions
- **Aisés** : offres standard

Visualisation : projection PCA 2D (les 4 dimensions réduites à un plan) pour visualiser la séparation des segments.

Conclusion & pistes

Démarche validée

- Détection + correction des valeurs aberrantes
- Choix de K par coude + silhouette + sens métier
- Comparaison à un autre algorithme (K-means validé)
- 4 segments commerciaux actionnables identifiés

Limites & pistes (B206)

- Silhouette modérée (~ 0.33) : groupes partiellement chevauchants (normal sur données réelles)
- Enrichir avec d'autres variables (région, aides)
- Tester un clustering basé densité (DBSCAN, cf. TP5)

Modèle retenu : K-means, K = 4

silhouette = 0,327 · Davies-Bouldin = 0,94 · 4 segments métier identifiés