

Machine Learning II — ADIF84

Lab 2 — Segmentation des districts par K-means

Identifier des profils-types de districts engagés pour cibler une démarche commerciale

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Tâche non supervisée — clustering

Introduction — Contexte du projet

26 M

élèves américains
prennent le bus scolaire
chaque matin

480 000

bus scolaires
en circulation
(majoritairement diesel)

19 516

districts scolaires
recensés dans
le dataset WRI

Ces bus circulent souvent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Depuis quelques années, des programmes fédéraux et des subventions accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

Source de données

Dataset of U.S. Electric School Bus Adoption

World Resources Institute / ESB Initiative

Feuille « District-level data »

Chaque ligne = un district scolaire

91 colonnes — socio-économiques,
environnementales, géographiques

1. Compréhension du problème métier

Ce TP — Segmentation par K-means (non supervisé)

« Existe-t-il des profils-types de districts engagés, vers lesquels adapter un discours commercial distinct ? »

Objectif business

Identifier des groupes naturels parmi les 1 524 districts déjà engagés, pour adapter la démarche commerciale à chaque profil de district.

Type de tâche

Clustering — non supervisé, descriptif.
Pas de variable cible à prédire.
On cherche une structure cachée.
Modèle : K-means (4 variables socio-éco).

Intérêt métier

Chaque segment → discours distinct :
— Grand district : offre de volume
— District précaire : mise en avant des aides
— Peu électrifié : accompagnement démarrage

Données : 1 524 districts engagés — 4 variables : % flotte électrique, nb élèves, % repas gratuits, % pauvreté.

1. Compréhension du problème métier

Objectif business

Identifier des **groupes (segments) de districts** parmi ceux déjà engagés dans les bus électriques, afin de mieux cibler une démarche commerciale / publicitaire.

Décideur visé : société de vente de bus électriques.

Question :

« Existe-t-il des profils-types de districts engagés, vers lesquels adapter un discours commercial distinct ? »

Type de tâche

Clustering — non supervisé

Pas de « bonne réponse » à prédire : on cherche une structure cachée dans les données (tâche descriptive).

4 variables socio-économiques

- % flotte électrique
- Nombre d'élèves (taille)
- % repas gratuits (précarité scolaire)
- % pauvreté

Exploitation commerciale : chaque segment appelle un discours distinct (extension de flotte, mise en avant des subventions, offres de volume...).

2. Compréhension des données

1 524

districts engagés (committed = yes)

4

variables retenues

22

valeurs aberrantes détectées

Détection de valeurs aberrantes

La variable « % flotte électrique » contenait des valeurs > 100 % (jusqu'à 2300 % !). Ce sont des erreurs de données. K-means étant très sensible aux valeurs extrêmes, elles fausseraient totalement le clustering. → Elles seront plafonnées à 100 % lors de la préparation.

Exploration menée

Taux de valeurs manquantes par variable (jusqu'à 19 % sur « % flotte électrique »), statistiques descriptives, et histogrammes des 4 variables — qui ont révélé les valeurs extrêmes ci-dessus.

3. Préparation des données d'entraînement

1

Correction des aberrants

« % flotte électrique » plafonné à 100 %. K-means minimise des distances au carré → un point aberrant accaparerait un cluster entier.

2

Imputation (médiane)

Valeurs manquantes remplacées par la médiane, robuste aux valeurs extrêmes (contrairement à la moyenne).

3

Standardisation

StandardScaler : indispensable car K-means repose sur des distances. Sans elle, « Nb élèves » (milliers) écraserait les % (0-1).

4

Export du jeu

Données préparées exportées en clustering.csv — livrable « fichier d'entraînement » demandé par le sujet.


Deux limites assumées

19 % de NA sur « % flotte électrique » imputés par la médiane (variable à interpréter avec prudence). On conserve les valeurs extrêmes légitimes (méga-districts comme NYC, LA) : ce ne sont pas des erreurs mais un vrai segment « très grands districts ».


4a. Choix du nombre de clusters K

Deux critères complémentaires pour choisir K : la méthode du coude (inertie) et le score de silhouette.

Méthode du coude — inertie selon K



Silhouette selon K — maximum à K = 4



Lecture des deux critères

Coude : la décroissance de l'inertie ralentit nettement après $K = 4$ (le « coude »). **Silhouette** : maximum atteint à $K = 4$ (0,327).
Les deux critères convergent vers $K = 4$. Affiné ensuite par grille $K \times \text{init}$ (14 combinaisons), puis validé par l'interprétation des profils.

4b. K=3 vs K=4 : comparaison des profils

Comparaison directe des profils obtenus avec K=3 et K=4 (z-scores : positif = au-dessus de la moyenne).

K = 3 · silhouette = 0,294

Segment	Taille	Caractéristique
Défavorisés	689	Forte pauvreté / repas gratuits
Aisés	814	Faible pauvreté
Très grands districts	21	Nb élèves très élevé (+6,8 σ)

K = 4 · silhouette = 0,327

Segment	Taille	Caractéristique
Pionniers	165	Forte électrification (+2,35 σ)
Aisés	734	Faible pauvreté
Défavorisés	604	Forte pauvreté / repas gratuits
Très grands districts	21	Nb élèves très élevé (+6,8 σ)



K = 4 retenu

Meilleure silhouette : 0,327 contre 0,294 pour K=3. **4 profils distincts et exploitables :** K=4 isole un segment « Pionniers » (165 districts à forte électrification) que K=3 fusionnait avec les Défavorisés.

Rôle clé du nettoyage : sans correction des valeurs aberrantes (% électrique > 100 %), K=4 créait un cluster d'un seul district — inutile. Après plafonnement à 100 %, ce 4^e segment devient un vrai groupe commercial pertinent.

4c. Comparaison avec un autre algorithme

Comparaison de K-means à un autre algorithme de clustering : l'agglomératif avec critère de Ward.



L'algorithme agglomératif en bref

- Chaque district démarre seul (1524 clusters).
- À chaque étape, on fusionne les 2 clusters les plus proches.
- On répète jusqu'à obtenir le nombre voulu (ici $K = 4$).

Critère de Ward = minimise la variance interne (analogue de K-means).

Conclusion

K-means bat l'agglomératif sur les deux métriques (silhouette et Davies-Bouldin).

Les deux algorithmes retrouvent la même structure en 4 groupes : la segmentation est robuste, ce n'est pas un artefact d'une méthode.

4. Modèle final retenu

K = 4

clusters retenus

0,327

silhouette globale

4

segments métier actionnables

Les 4 segments et leur ciblage commercial

- **Pionniers** : proposer l'extension de flotte
- **Très grands districts** : offres de volume
- **Défavorisés** : mettre en avant les subventions
- **Aisés** : offres standard

Visualisation : projection PCA 2D (les 4 dimensions réduites à un plan) pour visualiser la séparation des segments.

Conclusion & pistes

Démarche validée

- Détection + correction des valeurs aberrantes
- Choix de K par coude + silhouette + sens métier
- Comparaison à un autre algorithme (K-means validé)
- 4 segments commerciaux actionnables identifiés

Limites & pistes (B206)

- Silhouette modérée (~ 0.33) : groupes partiellement chevauchants (normal sur données réelles)
- Enrichir avec d'autres variables (région, aides)
- Tester un clustering basé densité (DBSCAN, cf. TP5)

Modèle retenu : K-means, K = 4

silhouette = 0,327 · Davies-Bouldin = 0,94 · 4 segments métier identifiés