

Lab 3 — Clustering hiérarchique des districts

Segmenter les districts engagés par classification hiérarchique — et valider la structure par confrontation à un autre algorithme

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

1. Compréhension du problème métier

Objectif business

Identifier des **groupes (segments) de districts scolaires** parmi ceux déjà engagés dans les bus électriques, afin de mieux cibler une démarche commerciale / publicitaire.

Décideur visé : *société de vente de bus électriques.*

Question

« Existe-t-il des profils-types de districts engagés, vers lesquels adapter un discours commercial distinct ? »

Type de tâche

Clustering — non supervisé, descriptif
(apprentissage non supervisé, descriptif).

Modèle imposé par le sujet : clustering hiérarchique. L'algorithme et son fonctionnement seront détaillés dans la partie « Choix et réglage du modèle ».

2. Compréhension des données

1 524

districts engagés
(committed = yes)

4

variables socio-
économiques retenues

jusqu'à 33 %

de valeurs manquantes
sur certaines variables

Variables retenues

% **flotte électrique** (niveau d'électrification déjà atteint)

Nb élèves (taille du district)

% **repas gratuits** (précarité scolaire)

% **pauvreté** (pauvreté de la population)

Détection de valeurs aberrantes

La variable « % flotte électrique » contient des valeurs supérieures à 100 %, jusqu'à 2300 %. Ce sont des erreurs de saisie (22 districts concernés) : un pourcentage ne peut physiquement pas dépasser 100 %. Ces valeurs seront corrigées lors de la préparation, car les algorithmes de clustering basés sur les distances sont très sensibles aux valeurs extrêmes.

3. Préparation des données d'entraînement

1

Filtrage

On ne garde que les districts déjà engagés (committed = yes) → 1524 lignes pour l'analyse.

2

Correction des aberrants

% flotte électrique plafonné à 100 % (clip à 1.0). 22 valeurs corrigées. Évite qu'un district aberrant accapare un cluster.

3

Imputation des manquants

Valeurs manquantes (jusqu'à 33 % sur certaines variables) remplacées par la médiane, robuste aux valeurs extrêmes.

4

Standardisation

StandardScaler appliqué aux 4 variables : moyenne 0, écart-type 1. Indispensable car les distances sont sensibles aux échelles (Nb élèves en milliers vs % en 0-1).

Livrable de cette étape

Le jeu de données préparé est exporté en **clustering.csv** (1524 districts × 4 variables, sans NA, standardisé) — c'est le « fichier des données d'entraînement » demandé par le sujet.

4a. L'algorithme : clustering hiérarchique

Approche agglomérative

1. Chaque district démarre comme son propre cluster (1524 clusters au départ).
2. À chaque étape, on fusionne les deux clusters les plus proches.
3. On répète jusqu'à n'avoir qu'un seul cluster contenant tout.

Sortie : le dendrogramme

Un arbre qui enregistre l'ordre des fusions. La **hauteur d'une fusion** = la distance entre les deux groupes (plus c'est haut, plus ils étaient différents).

Pourquoi cet algorithme ?

Pas besoin de fixer le nombre de clusters à l'avance

On construit l'arbre complet, puis on coupe à la hauteur qui révèle le bon nombre de groupes (méthode visuelle).

Algorithme déterministe

Pas d'initialisation aléatoire (contrairement à K-means) : le résultat est reproductible.

Paramètre clé à régler : le linkage

Comment mesurer la « distance » entre deux clusters ? 4 stratégies possibles (single, complete, average, Ward) — on compare leurs résultats à la slide suivante.

4b. Le dendrogramme — choix du nombre de clusters

Dendrogramme calculé avec le linkage de Ward (le linkage est détaillé à la slide suivante).


Comment lire le dendrogramme

La **hauteur d'une fusion** représente la distance entre les deux clusters qui fusionnent. Plus c'est haut, plus ces clusters étaient différents.

Pour **obtenir K clusters**, on « coupe » l'arbre par une ligne horizontale. Le nombre de branches traversées = le nombre de groupes.

Choisir K en pratique

On coupe l'arbre là où il y a le **plus grand saut vertical** entre deux fusions consécutives. Sur nos données : saut net de 26 à 43 (cf. dendrogramme).



Lecture du dendrogramme

La **ligne rouge pointillée à $h \approx 35$** traverse 4 branches verticales : **4 clusters retenus**.
La hauteur 35 est choisie dans le grand vide entre 26 et 43 — n'importe quelle valeur dans ce trou donne le même découpage.

4c. Les 4 linkages : qu'est-ce que c'est ?

Le « linkage » définit comment mesurer la distance entre deux clusters (un cluster contient plusieurs points). Quatre stratégies du cours.

Single (MIN)

Définition : Distance des deux points les plus PROCHES entre les deux clusters.

Caractéristique : *Sensible au bruit, effet de chaînage.*

Complete (MAX)

Définition : Distance des deux points les plus ÉLOIGNÉS entre les deux clusters.

Caractéristique : *Tend à fragmenter les gros clusters.*

Average

Définition : MOYENNE de toutes les distances point-à-point entre les deux clusters.

Caractéristique : *Compromis entre single et complete.*

Ward

Définition : Minimise l'augmentation de variance après la fusion (analogue hiérarchique de K-means).

Caractéristique : *Clusters compacts et équilibrés.*

4d. Comparaison des linkages sur nos données

On applique les 4 linkages au même jeu de données ($K = 4$) et on compare les résultats — silhouette, tailles des clusters, verdict.

Linkage	Silhouette	Tailles des 4 clusters	Verdict
single (MIN)	0.756	1519 / 3 / 1 / 1	dégénéré
average	0.670	1511 / 8 / 4 / 1	dégénéré
complete (MAX)	0.249	972 / 539 / 9 / 4	déséquilibré
Ward	0.302	711 / 697 / 96 / 20	★ équilibré

Effet de chaînage des linkages single et average

Single et average ont la silhouette la plus haute (0,76 et 0,67) mais regroupent ~1500 districts dans un seul cluster — phénomène décrit dans le cours (ch.2). Ward produit 4 groupes équilibrés (711 / 697 / 96 / 20), exploitables pour la suite. La vérification des tailles est nécessaire en plus du score métrique.

4e. K-means en bref

Avant de comparer notre clustering hiérarchique à K-means, deux mots sur ce second algorithme — partitionnel et très différent du nôtre.

Principe : algorithme partitionnel

1. On fixe K à l'avance (ici $K = 4$) et on place K centres au hasard.
2. Chaque district est affecté au centre le plus proche.
3. Chaque centre se déplace au milieu des points qu'il a attirés.
4. On répète 2-3 jusqu'à ce que les centres ne bougent plus.

Sortie : une partition

Chaque district est affecté à exactement un cluster, sans hiérarchie ni arbre.

Différences avec le hiérarchique

	K-means	Hiérarchique
Nombre K	fixé AVANT (paramètre)	choisi APRÈS (coupe de l'arbre)
Méthode	K centres ajustés en boucle	fusions successives des plus proches
Reproductible ?	non (dépend du tirage initial)	oui (déterministe)
Vitesse	très rapide, scalable	lent : $O(N^2)$

Deux algorithmes au fonctionnement opposé : c'est pour ça que leur accord (slide suivante) est significatif.

4f. Validation croisée par K-means

Pour vérifier la robustesse de la segmentation, on applique en parallèle K-means (algorithme partitionnel, différent du hiérarchique) sur les mêmes données, et on mesure l'accord entre les deux partitions.

0,705

Adjusted Rand Index

mesure l'accord entre 2 partitions

0 = hasard · 1 = identique

Fort accord

Interprétation

Deux algorithmes de clustering très différents — K-means (partitionnel, K centres ajustés) et hiérarchique agglomératif (fusions successives) — **retrouvent essentiellement la même structure en 4 groupes** sur les 1524 districts.

→ **La segmentation est robuste** : ce n'est pas un artefact d'une méthode, mais une vraie structure des données.

Les 4 segments retrouvés : **Pionniers (96), Aisés (711), Défavorisés (697), Très grands districts (20).**

4g. Les 4 segments retenus

Caractérisation des 4 clusters obtenus avec Ward — taille, profil dominant et discours commercial associé.

Pionniers

96 districts

% flotte électrique $+2,97 \sigma$

Districts déjà très avancés dans l'électrification de leur flotte.

→ **Action commerciale** : Extension de flotte, services premium.

Très grands districts

20 districts

Nb élèves $+7,01 \sigma$

Méga-districts type New York, Los Angeles — très peu nombreux mais énormes.

→ **Action commerciale** : Offres de volume, contrats sur mesure.

Défavorisés

697 districts

% pauvreté $+0,57 \sigma$ · % repas gratuits $+0,77 \sigma$

Districts à forte précarité socio-économique.

→ **Action commerciale** : Mise en avant des subventions fédérales (EPA).

Aisés

711 districts

% pauvreté $-0,52 \sigma$ · % repas gratuits $-0,75 \sigma$

Districts plutôt favorisés, peu de précarité.

→ **Action commerciale** : Offres standard, démarche commerciale classique.

Conclusion & pistes

Démarche validée

- Dendrogramme (Ward) pour visualiser la structure
- Comparaison de 4 linkages + détection du piège single/average
- Vérification des tailles, pas seulement du score
- 4 segments confirmés par validation croisée avec K-means (ARI = 0,705)

Limites & pistes (B206)

- Coût $O(N^2)$: moins adapté aux très gros volumes que K-means
- Silhouette modérée (chevauchement partiel des groupes)
- Piste : clustering basé densité (DBSCAN) pour des formes non sphériques

Modèle retenu : Hiérarchique Ward, K = 4

silhouette = 0,302 · ARI vs K-means = 0,705 · 4 segments métier identifiés