

Machine Learning II — ADIF84

Lab 3 — Clustering hiérarchique des districts

Segmenter les districts engagés par classification hiérarchique — et valider la structure par confrontation à un autre algorithme

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Modèle imposé par le sujet : clustering hiérarchique

Introduction — Contexte du projet

26 M

élèves américains
prennent le bus scolaire
chaque matin

480 000

bus scolaires
en circulation
(majoritairement diesel)

19 516

districts scolaires
recensés dans
le dataset WRI

Ces bus circulent souvent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Depuis quelques années, des programmes fédéraux et des subventions accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

Source de données

Dataset of U.S. Electric School Bus Adoption

World Resources Institute / ESB Initiative

Feuille « District-level data »

Chaque ligne = un district scolaire

91 colonnes — socio-économiques,
environnementales, géographiques

1. Compréhension du problème métier

Ce TP — Clustering hiérarchique agglomératif

« *Quels groupes de districts engagés peut-on identifier — et la structure confirme-t-elle celle du K-means ?* »

Objectif business

Segmenter les 1 524 districts engagés sans fixer le nombre de groupes à l'avance. Le nombre se lit dans l'arbre de fusions (dendrogramme).

Type de tâche

Clustering hiérarchique agglomératif.
Tâche descriptive non supervisée.
Modèle imposé par le sujet.
Mêmes 4 variables que le TP2 → comparaison.

Intérêt métier

Valider ou infirmer la structure K-means.
Piège connu : l'effet de chaînage donne de bons scores mais des groupes inutilisables — l'interprétation prime.

Avantage clé : contrairement au K-means, le nombre de clusters n'est pas fixé a priori — il émerge du dendrogramme.

1. Compréhension du problème métier

Objectif business

Identifier des **groupes (segments) de districts scolaires** parmi ceux déjà engagés dans les bus électriques, afin de mieux cibler une démarche commerciale / publicitaire.

Décideur visé : *société de vente de bus électriques.*

Question

« Existe-t-il des profils-types de districts engagés, vers lesquels adapter un discours commercial distinct ? »

Type de tâche

Clustering — non supervisé, descriptif
(apprentissage non supervisé, descriptif).

Modèle imposé par le sujet : clustering hiérarchique. L'algorithme et son fonctionnement seront détaillés dans la partie « Choix et réglage du modèle ».

2. Compréhension des données

1 524

districts engagés
(committed = yes)

4

variables socio-
économiques retenues

jusqu'à 33 %

de valeurs manquantes
sur certaines variables

Variables retenues

% **flotte électrique** (niveau d'électrification déjà atteint)

Nb élèves (taille du district)

% **repas gratuits** (précarité scolaire)

% **pauvreté** (pauvreté de la population)

Détection de valeurs aberrantes

La variable « % flotte électrique » contient des valeurs supérieures à 100 %, jusqu'à 2300 %. Ce sont des erreurs de saisie (22 districts concernés) : un pourcentage ne peut physiquement pas dépasser 100 %. Ces valeurs seront corrigées lors de la préparation, car les algorithmes de clustering basés sur les distances sont très sensibles aux valeurs extrêmes.

3. Préparation des données d'entraînement

1

Filtrage

On ne garde que les districts déjà engagés (committed = yes) → 1524 lignes pour l'analyse.

2

Correction des aberrants

% flotte électrique plafonné à 100 % (clip à 1.0). 22 valeurs corrigées. Évite qu'un district aberrant accapare un cluster.

3

Imputation des manquants

Valeurs manquantes (jusqu'à 33 % sur certaines variables) remplacées par la médiane, robuste aux valeurs extrêmes.

4

Standardisation

StandardScaler appliqué aux 4 variables : moyenne 0, écart-type 1. Indispensable car les distances sont sensibles aux échelles (Nb élèves en milliers vs % en 0-1).

Livrable de cette étape

Le jeu de données préparé est exporté en **clustering.csv** (1524 districts × 4 variables, sans NA, standardisé) — c'est le « fichier des données d'entraînement » demandé par le sujet.

4a. L'algorithme : clustering hiérarchique

Approche agglomérative

1. Chaque district démarre comme son propre cluster (1524 clusters au départ).
2. À chaque étape, on fusionne les deux clusters les plus proches.
3. On répète jusqu'à n'avoir qu'un seul cluster contenant tout.

Sortie : le dendrogramme

Un arbre qui enregistre l'ordre des fusions. La **hauteur d'une fusion** = la distance entre les deux groupes (plus c'est haut, plus ils étaient différents).

Pourquoi cet algorithme ?

Pas besoin de fixer le nombre de clusters à l'avance

On construit l'arbre complet, puis on coupe à la hauteur qui révèle le bon nombre de groupes (méthode visuelle).

Algorithme déterministe

Pas d'initialisation aléatoire (contrairement à K-means) : le résultat est reproductible.

Paramètre clé à régler : le linkage

Comment mesurer la « distance » entre deux clusters ? 4 stratégies possibles (single, complete, average, Ward) — on compare leurs résultats à la slide suivante.

4b. Le dendrogramme — choix du nombre de clusters

Dendrogramme calculé avec le linkage de Ward (le linkage est détaillé à la slide suivante).


Comment lire le dendrogramme

La **hauteur d'une fusion** représente la distance entre les deux clusters qui fusionnent. Plus c'est haut, plus ces clusters étaient différents.

Pour **obtenir K clusters**, on « coupe » l'arbre par une ligne horizontale. Le nombre de branches traversées = le nombre de groupes.

Choisir K en pratique

On coupe l'arbre là où il y a le **plus grand saut vertical** entre deux fusions consécutives. Sur nos données : saut net de 26 à 43 (cf. dendrogramme).



Lecture du dendrogramme

La **ligne rouge pointillée à $h \approx 35$** traverse 4 branches verticales : **4 clusters retenus**. La hauteur 35 est choisie dans le grand vide entre 26 et 43 — n'importe quelle valeur dans ce trou donne le même découpage.

4c. Les 4 linkages : qu'est-ce que c'est ?

Le « linkage » définit comment mesurer la distance entre deux clusters (un cluster contient plusieurs points). Quatre stratégies du cours.

Single (MIN)

Définition : Distance des deux points les plus PROCHES entre les deux clusters.

Caractéristique : Sensible au bruit, effet de chaînage.

Complete (MAX)

Définition : Distance des deux points les plus ÉLOIGNÉS entre les deux clusters.

Caractéristique : Tend à fragmenter les gros clusters.

Average

Définition : MOYENNE de toutes les distances point-à-point entre les deux clusters.

Caractéristique : Compromis entre single et complete.

Ward

Définition : Minimise l'augmentation de variance après la fusion (analogue hiérarchique de K-means).

Caractéristique : Clusters compacts et équilibrés.

4d. Comparaison des linkages sur nos données

On applique les 4 linkages au même jeu de données ($K = 4$) et on compare les résultats — silhouette, tailles des clusters, verdict.

Linkage	Silhouette	Tailles des 4 clusters	Verdict
single (MIN)	0.756	1519 / 3 / 1 / 1	dégénéré
average	0.670	1511 / 8 / 4 / 1	dégénéré
complete (MAX)	0.249	972 / 539 / 9 / 4	déséquilibré
Ward	0.302	711 / 697 / 96 / 20	★ équilibré

Effet de chaînage des linkages single et average

Single et average ont la silhouette la plus haute (0,76 et 0,67) mais regroupent ~1500 districts dans un seul cluster — phénomène décrit dans le cours (ch.2). Ward produit 4 groupes équilibrés (711 / 697 / 96 / 20), exploitables pour la suite. La vérification des tailles est nécessaire en plus du score métrique.

4e. K-means en bref

Avant de comparer notre clustering hiérarchique à K-means, deux mots sur ce second algorithme — partitionnel et très différent du nôtre.

Principe : algorithme partitionnel

1. On fixe K à l'avance (ici $K = 4$) et on place K centres au hasard.
2. Chaque district est affecté au centre le plus proche.
3. Chaque centre se déplace au milieu des points qu'il a attirés.
4. On répète 2-3 jusqu'à ce que les centres ne bougent plus.

Sortie : une partition

Chaque district est affecté à exactement un cluster, sans hiérarchie ni arbre.

Différences avec le hiérarchique

	K-means	Hiérarchique
Nombre K	fixé AVANT (paramètre)	choisi APRÈS (coupe de l'arbre)
Méthode	K centres ajustés en boucle	fusions successives des plus proches
Reproductible ?	non (dépend du tirage initial)	oui (déterministe)
Vitesse	très rapide, scalable	lent : $O(N^2)$

Deux algorithmes au fonctionnement opposé : c'est pour ça que leur accord (slide suivante) est significatif.

4f. Validation croisée par K-means

Pour vérifier la robustesse de la segmentation, on applique en parallèle K-means (algorithme partitionnel, différent du hiérarchique) sur les mêmes données, et on mesure l'accord entre les deux partitions.

0,705

Adjusted Rand Index

mesure l'accord entre 2 partitions

0 = hasard · 1 = identique

Fort accord

Interprétation

Deux algorithmes de clustering très différents — K-means (partitionnel, K centres ajustés) et hiérarchique agglomératif (fusions successives) — **retrouvent essentiellement la même structure en 4 groupes** sur les 1524 districts.

→ La **segmentation est robuste** : ce n'est pas un artefact d'une méthode, mais une vraie structure des données.

Les 4 segments retrouvés : **Pionniers (96), Aisés (711), Défavorisés (697), Très grands districts (20).**

4g. Les 4 segments retenus

Caractérisation des 4 clusters obtenus avec Ward — taille, profil dominant et discours commercial associé.

Pionniers

96 districts

% flotte électrique $+2,97 \sigma$

Districts déjà très avancés dans l'électrification de leur flotte.

→ **Action commerciale** : Extension de flotte, services premium.

Très grands districts

20 districts

Nb élèves $+7,01 \sigma$

Méga-districts type New York, Los Angeles — très peu nombreux mais énormes.

→ **Action commerciale** : Offres de volume, contrats sur mesure.

Défavorisés

697 districts

% pauvreté $+0,57 \sigma$ · % repas gratuits $+0,77 \sigma$

Districts à forte précarité socio-économique.

→ **Action commerciale** : Mise en avant des subventions fédérales (EPA).

Aisés

711 districts

% pauvreté $-0,52 \sigma$ · % repas gratuits $-0,75 \sigma$

Districts plutôt favorisés, peu de précarité.

→ **Action commerciale** : Offres standard, démarche commerciale classique.

Conclusion & pistes

Démarche validée

- Dendrogramme (Ward) pour visualiser la structure
- Comparaison de 4 linkages + détection du piège single/average
- Vérification des tailles, pas seulement du score
- 4 segments confirmés par validation croisée avec K-means (ARI = 0,705)

Limites & pistes (B206)

- Coût $O(N^2)$: moins adapté aux très gros volumes que K-means
- Silhouette modérée (chevauchement partiel des groupes)
- Piste : clustering basé densité (DBSCAN) pour des formes non sphériques

Modèle retenu : Hiérarchique Ward, K = 4

silhouette = 0,302 · ARI vs K-means = 0,705 · 4 segments métier identifiés