

Lab 4 — Profils des districts engagés

Découverte d'associations à l'aide de l'algorithme Apriori

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

1. Compréhension du problème métier

Objectif business

Identifier les **combinaisons de caractéristiques fréquentes** chez les districts scolaires déjà engagés dans la transition électrique (statuts committed / operating / delivering).

Cela permet de dresser des **profils-types** et de mieux comprendre quelles conditions favorisent l'adoption — utile pour orienter une démarche commerciale.

Question

« Quelles combinaisons d'attributs (revenus, localisation, pauvreté, pollution...) retrouve-t-on le plus souvent chez les districts engagés ? »

Type de tâche

Découverte d'associations

(non supervisée, descriptive — recherche d'itemsets fréquents).

Modèle imposé par le sujet : Apriori. L'algorithme et son fonctionnement seront détaillés dans la partie « Choix et réglage du modèle ».

2. Compréhension des données

19 517

districts scolaires
(transactions)

13

attributs binaires
(items)

8 %

districts engagés
(1 559 sur 19 517)

Les 13 attributs binaires (0 / 1), regroupés en 4 catégories

Engagement ESB

committed · operating · delivering

Géographie

urban · rural · large_district ·
small_district

Contexte économique

high_income · low_income · high_poverty ·
high_need

Politique publique

epa_2023 · pollution_burden

Spécificité du jeu de données

92 % de districts non-engagés vs 8 % engagés. L'analyse Apriori portera uniquement sur les 1 559 districts engagés pour révéler leurs profils. La densité passe de 28 % (tous) à 45 % (engagés), avec 5,8 attributs moyens par district engagé contre 3,5 sinon.

3. Préparation des données d'entraînement

1

Filtrage

On ne garde que les districts engagés (committed = 1 OU operating = 1 OU delivering = 1) → 1 559 transactions à analyser.

2

Construction des transactions

Chaque district = 1 transaction. Chaque attribut à 1 = 1 item dans la transaction. Ex : {committed, urban, high_income, large_district}.

3

Encodage one-hot

TransactionEncoder convertit la liste de transactions en matrice booléenne $1\,559 \times 13$, format attendu par Apriori.

4

Choix des seuils

min_support = 5 % et min_confidence = 40 %. Compromis quantité / qualité — détaillé à la slide 4d.

Livrable de cette étape

Le jeu d'entraînement **apriori_data_simplified.csv** ($19\,517$ districts $\times$ 13 attributs binaires) — c'est le « fichier des données d'entraînement » demandé par le sujet, déjà encodé en format transactionnel.

4a. L'algorithme Apriori

Apriori est l'algorithme de référence pour la découverte d'itemsets fréquents dans des données transactionnelles.

Principe : recherche itérative

1. Lister tous les items individuels apparaissant dans $\geq \text{min_support}$ des transactions (itemsets de taille 1).
2. Générer les itemsets candidats de taille 2 en combinant ceux trouvés.
3. Filtrer ceux dont le support est $\geq \text{min_support}$.
4. Répéter en augmentant la taille (3, 4, 5...) jusqu'à ce qu'aucun nouvel itemset fréquent n'apparaisse.

Propriété clé : si un itemset est fréquent, tous ses sous-ensembles le sont aussi (anti-monotonie). Permet d'élaguer massivement l'espace de recherche.

Exemple sur nos données

Une transaction (district engagé) :

```
{ committed, operating, low_income,  
  high_poverty, high_need, large_district }
```

Apriori cherche les sous-ensembles d'items qui apparaissent **ensemble fréquemment** dans les 1 559 transactions.

Ex. : { **high_poverty, large_district** } apparaît dans 43 % des districts engagés → itemset fréquent.

4b. Les trois métriques clés

Une règle d'association se note $A \rightarrow B$ (« si A, alors B »). On évalue chaque règle avec trois métriques complémentaires.

Support

$$\text{Support}(A \rightarrow B) = P(A \cap B)$$

Fréquence à laquelle A et B apparaissent ensemble dans les transactions.

À quoi ça sert : Filtrer les règles trop rares pour être utiles (bruit).

Confiance

$$\text{Confiance}(A \rightarrow B) = P(B \mid A)$$

Probabilité de B sachant A. « Si une transaction contient A, quelle fraction contient aussi B ? »

À quoi ça sert : Mesurer la fiabilité de la règle (en %).

Lift

$$\text{Lift}(A \rightarrow B) = P(B \mid A) / P(B)$$


Compare la confiance à la fréquence de base de B. Lift > 1 → A et B sont positivement corrélés.

À quoi ça sert : Distinguer les vraies associations du hasard.

4c. Itemsets fréquents extraits

Avec $\text{min_support} = 5\%$, Apriori extrait 617 itemsets fréquents — dont 73 de taille ≤ 2 et 544 de taille ≥ 3 .

Top 10 attributs présents chez les districts engagés



Lecture

- 74 % des districts engagés sont de grands districts (large_district).
- 57 % ont un fort besoin scolaire (high_need).
- 54 % opèrent déjà des bus électriques (operating).
- 53 % ont un taux de pauvreté élevé.

Combinaisons fréquentes (taille ≥ 2) :

{high_poverty, large_district} : 43 % des engagés.
{high_need, large_district} : 45 %.

4d. Règles d'association extraites

Avec `min_confidence = 40 %`, 5 709 règles sont générées. On se concentre sur celles à fort lift (associations significatives).

5 709

règles générées

4,73

lift maximum atteint

62 %

confiance de la règle
au plus fort lift

Règle au lift le plus élevé

`high_poverty & low_income & small_district` → `epa_2023 & high_need & rural`

Support 5,1 % · Confiance 62 % · Lift 4,73

Interprétation métier

Les districts **petits, pauvres et à bas revenus** sont 4,73 fois plus susceptibles d'être **prioritaires EPA, à forts besoins et ruraux** que la moyenne (lift = 4,73 $\gg$ 1). C'est exactement la cible des programmes fédéraux de subvention pour bus électriques.

→ *Action commerciale : prioriser ces districts dans les démarches liées aux subventions EPA.*

4e. L'algorithme Eclat

Avant la comparaison, deux mots sur Eclat — un second algorithme d'extraction d'itemsets fréquents, qu'on utilisera pour valider Apriori.

Principe : parcours en profondeur

1. Représentation verticale : pour chaque item, on stocke la liste des transactions qui le contiennent (TID-set).
2. On explore l'arbre des itemsets en profondeur : on prend un item, on combine avec un suivant, on continue tant que l'itemset est fréquent.
3. Calcul du support par intersection de TID-sets — pas besoin de relire le jeu de données.

Astuce clé : le support d'un itemset = taille de l'intersection des TID-sets des items. Beaucoup plus rapide qu'un scan complet des transactions.

Différences avec Apriori

	Apriori	Eclat
Parcours	Largeur d'abord	Profondeur d'abord
Format	horizontal (transactions × items)	vertical (item → TID-set)
Calcul support	scan des transactions	intersection de TID-sets
Mémoire	modérée	plus gourmande (gros TID-sets)

Les deux algorithmes résolvent le même problème (trouver les itemsets fréquents) mais avec des stratégies opposées.

4f. Comparaison Apriori vs Eclat sur nos données

Maintenant qu'on a les deux algorithmes, on les applique aux mêmes données et on compare leurs résultats.

Critère	Apriori	Eclat
Approche	Largeur d'abord (niveau par niveau)	Profondeur d'abord (vertical)
Représentation	Horizontale (transactions × items)	Verticale (items × TID-set)
Itemsets trouvés	617	617
Temps d'exécution	rapide	très rapide (~0,008 s)

Conclusion

Résultats identiques : les deux algorithmes trouvent exactement les mêmes 617 itemsets fréquents — c'est attendu, ils cherchent la même chose, juste avec une stratégie différente.

Eclat est plus rapide grâce à son format vertical, mais Apriori reste le plus utilisé pour son interprétabilité et son support natif dans mlxtend.

Sur 1 559 transactions, l'écart de performance est négligeable. **On garde Apriori** car il est mieux documenté et plus simple à expliquer.

4g. Profils-types des districts engagés

Synthèse des associations en 4 profils-types, chacun avec son action commerciale associée.

Précaires ruraux subventionnés

high_poverty + low_income + small_district + epa_2023 + rural

Petits districts ruraux à bas revenus et forte pauvreté, ciblés par le programme fédéral EPA 2023.

→ **Action** : Mise en avant des subventions, accompagnement administratif.

Grands districts en opération

operating + large_district + high_need

Grands districts ayant déjà des bus électriques en opération, à forts besoins scolaires.

→ **Action** : Extension de flotte, services premium et maintenance.

Aisés urbains

high_income + urban (souvent large_district)

Districts urbains à revenus élevés, généralement de grande taille.

→ **Action** : Offres standard, démonstration ROI et image écologique.

Charge polluante élevée

pollution_burden + epa_2023 + committed

Districts identifiés par EPA pour leur exposition à la pollution.

→ **Action** : Argument santé publique, partenariats locaux.

Conclusion & pistes

Démarche validée

- 617 itemsets fréquents extraits par Apriori (min_support = 5 %)
- 5 709 règles d'association générées (min_confidence = 40 %)
- Comparaison à Eclat : résultats identiques, choix d'Apriori validé
- 4 profils-types métier identifiés avec actions commerciales associées

Limites & pistes (B206)

- Beaucoup de règles redondantes (committed dans 100 % des transactions)
- Pas de comparaison directe entre profils engagés et non-engagés
- Piste : tester d'autres seuils support / confidence, explorer FP-Growth

Modèle retenu : Apriori (min_support = 5 %, min_confidence = 40 %)
617 itemsets · 5 709 règles · lift max 4,73 · 4 profils métier identifiés