

Lab 4 — Profils des districts engagés

Découverte d'associations à l'aide de l'algorithme Apriori

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Introduction — Contexte du projet

26 M

élèves américains
prennent le bus scolaire
chaque matin

480 000

bus scolaires
en circulation
(majoritairement diesel)

19 516

districts scolaires
recensés dans
le dataset WRI

Ces bus circulent souvent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Depuis quelques années, des programmes fédéraux et des subventions accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

Source de données

Dataset of U.S. Electric School Bus Adoption

World Resources Institute / ESB Initiative

Feuille « District-level data »

Chaque ligne = un district scolaire

91 colonnes — socio-économiques,
environnementales, géographiques

1. Compréhension du problème métier

Ce TP — Règles d'association (Apriori)

« Quelles combinaisons d'attributs retrouve-t-on le plus souvent chez les districts engagés ? »

Objectif business

Identifier les combinaisons de conditions fréquentes chez les 1 559 districts engagés.
On ne prédit pas — on comprend ce qui favorise l'adoption.

Type de tâche

Découverte d'associations — Apriori.
Analyse descriptive non supervisée.
19 517 districts — 13 attributs binaires.
Modèle imposé par le sujet.

Intérêt métier

Cibler les profils favorables.
Adapter le discours commercial.
Évaluer l'équité : la transition profite-t-elle à tous les districts ?

Comme en grande distribution : « les clients qui achètent du pain achètent aussi du beurre » — ici on remplace les produits par des attributs de districts.

1. Compréhension du problème métier

Objectif business

Identifier les **combinaisons de caractéristiques fréquentes** chez les districts scolaires déjà engagés dans la transition électrique (statuts committed / operating / delivering).

Cela permet de dresser des **profils-types** et de mieux comprendre quelles conditions favorisent l'adoption — utile pour orienter une démarche commerciale.

Question

« Quelles combinaisons d'attributs (revenus, localisation, pauvreté, pollution...) retrouve-t-on le plus souvent chez les districts engagés ? »

Type de tâche

Découverte d'associations

(non supervisée, descriptive — recherche d'itemsets fréquents).

Modèle imposé par le sujet : Apriori. L'algorithme et son fonctionnement seront détaillés dans la partie « Choix et réglage du modèle ».

2. Compréhension des données

19 517

districts scolaires
(transactions)

13

attributs binaires
(items)

8 %

districts engagés
(1 559 sur 19 517)

Les 13 attributs binaires (0 / 1), regroupés en 4 catégories

Engagement ESB

committed · operating · delivering

Contexte économique

high_income · low_income ·
high_poverty · high_need

Géographie

urban · rural · large_district ·
small_district

Politique publique

epa_2023 · pollution_burden

Spécificité du jeu de données

92 % de districts non-engagés vs 8 % engagés. L'analyse Apriori portera uniquement sur les 1 559 districts engagés pour révéler leurs profils. La densité passe de 28 % (tous) à 45 % (engagés), avec 5,8 attributs moyens par district engagé contre 3,5 sinon.

3. Préparation des données d'entraînement

1

Filtrage

On ne garde que les districts engagés (committed = 1 OU operating = 1 OU delivering = 1) → 1 559 transactions à analyser.

2

Construction des transactions

Chaque district = 1 transaction. Chaque attribut à 1 = 1 item dans la transaction. Ex : {committed, urban, high_income, large_district}.

3

Encodage one-hot

TransactionEncoder convertit la liste de transactions en matrice booléenne $1\,559 \times 13$, format attendu par Apriori.

4

Choix des seuils

min_support = 5 % et min_confidence = 40 %. Compromis quantité / qualité — détaillé à la slide 4d.

Livrable de cette étape

Le jeu d'entraînement **apriori_data_simplified.csv** ($19\,517$ districts $\times$ 13 attributs binaires) — c'est le « fichier des données d'entraînement » demandé par le sujet, déjà encodé en format transactionnel.

4a. L'algorithme Apriori

Apriori est l'algorithme de référence pour la découverte d'itemsets fréquents dans des données transactionnelles.

Principe : recherche itérative

1. Lister tous les items individuels apparaissant dans $\geq \text{min_support}$ des transactions (itemsets de taille 1).
2. Générer les itemsets candidats de taille 2 en combinant ceux trouvés.
3. Filtrer ceux dont le support est $\geq \text{min_support}$.
4. Répéter en augmentant la taille (3, 4, 5...) jusqu'à ce qu'aucun nouvel itemset fréquent n'apparaisse.

Propriété clé : si un itemset est fréquent, tous ses sous-ensembles le sont aussi (anti-monotonie). Permet d'élaguer massivement l'espace de recherche.

Exemple sur nos données

Une transaction (district engagé) :

```
{ committed, operating, low_income,  
  high_poverty, high_need, large_district }
```

Apriori cherche les sous-ensembles d'items qui apparaissent **ensemble fréquemment** dans les 1 559 transactions.

Ex. : { **high_poverty**, **large_district** } apparaît dans 43 % des districts engagés → itemset fréquent.

4b. Les trois métriques clés

Une règle d'association se note $A \rightarrow B$ (« si A, alors B »). On évalue chaque règle avec trois métriques complémentaires.

Support

$$\text{Support}(A \rightarrow B) = P(A \cap B)$$

Fréquence à laquelle A et B apparaissent ensemble dans les transactions.

À quoi ça sert : Filtrer les règles trop rares pour être utiles (bruit).

Confiance

$$\text{Confiance}(A \rightarrow B) = P(B \mid A)$$

Probabilité de B sachant A. « Si une transaction contient A, quelle fraction contient aussi B ? »

À quoi ça sert : Mesurer la fiabilité de la règle (en %).

Lift

$$\text{Lift}(A \rightarrow B) = P(B \mid A) / P(B)$$


Compare la confiance à la fréquence de base de B. $\text{Lift} > 1 \rightarrow A$ et B sont positivement corrélés.

À quoi ça sert : Distinguer les vraies associations du hasard.

4c. Itemsets fréquents extraits

Avec $\text{min_support} = 5\%$, Apriori extrait 617 itemsets fréquents — dont 73 de taille ≤ 2 et 544 de taille ≥ 3 .

Top 10 attributs présents chez les districts engagés



Lecture

- 74 % des districts engagés sont de grands districts (`large_district`).
- 57 % ont un fort besoin scolaire (`high_need`).
- 54 % opèrent déjà des bus électriques (`operating`).
- 53 % ont un taux de pauvreté élevé.

Combinaisons fréquentes (taille ≥ 2) :

`{high_poverty, large_district}` : 43 % des engagés.
`{high_need, large_district}` : 45 %.

4d. Règles d'association extraites

Avec `min_confidence = 40 %`, 5 709 règles sont générées. On se concentre sur celles à fort lift (associations significatives).

5 709

règles générées

4,73

lift maximum atteint

62 %

confiance de la règle
au plus fort lift

Règle au lift le plus élevé

`high_poverty & low_income & small_district` → `epa_2023 & high_need & rural`

Support 5,1 % · Confiance 62 % · Lift 4,73

Interprétation métier

Les districts **petits, pauvres et à bas revenus** sont 4,73 fois plus susceptibles d'être **prioritaires EPA, à forts besoins et ruraux** que la moyenne (lift = 4,73 $\gg$ 1). C'est exactement la cible des programmes fédéraux de subvention pour bus électriques.

→ *Action commerciale : prioriser ces districts dans les démarches liées aux subventions EPA.*

4e. L'algorithme Eclat

Avant la comparaison, deux mots sur Eclat — un second algorithme d'extraction d'itemsets fréquents, qu'on utilisera pour valider Apriori.

Principe : parcours en profondeur

1. Représentation verticale : pour chaque item, on stocke la liste des transactions qui le contiennent (TID-set).
2. On explore l'arbre des itemsets en profondeur : on prend un item, on combine avec un suivant, on continue tant que l'itemset est fréquent.
3. Calcul du support par intersection de TID-sets — pas besoin de relire le jeu de données.

Astuce clé : le support d'un itemset = taille de l'intersection des TID-sets des items. Beaucoup plus rapide qu'un scan complet des transactions.

Différences avec Apriori

	Apriori	Eclat
Parcours	Largeur d'abord	Profondeur d'abord
Format	horizontal (transactions × items)	vertical (item → TID-set)
Calcul support	scan des transactions	intersection de TID-sets
Mémoire	modérée	plus gourmande (gros TID-sets)

Les deux algorithmes résolvent le même problème (trouver les itemsets fréquents) mais avec des stratégies opposées.

4f. Comparaison Apriori vs Eclat sur nos données

Maintenant qu'on a les deux algorithmes, on les applique aux mêmes données et on compare leurs résultats.

Critère	Apriori	Eclat
Approche	Largeur d'abord (niveau par niveau)	Profondeur d'abord (vertical)
Représentation	Horizontale (transactions × items)	Verticale (items × TID-set)
Itemsets trouvés	617	617
Temps d'exécution	rapide	très rapide (~0,008 s)

Conclusion

Résultats identiques : les deux algorithmes trouvent exactement les mêmes 617 itemsets fréquents — c'est attendu, ils cherchent la même chose, juste avec une stratégie différente.

Eclat est plus rapide grâce à son format vertical, mais Apriori reste le plus utilisé pour son interprétabilité et son support natif dans mlxtend.

Sur 1 559 transactions, l'écart de performance est négligeable. **On garde Apriori** car il est mieux documenté et plus simple à expliquer.

4g. Profils-types des districts engagés

Synthèse des associations en 4 profils-types, chacun avec son action commerciale associée.

Précaires ruraux subventionnés

high_poverty + low_income + small_district + epa_2023 + rural

Petits districts ruraux à bas revenus et forte pauvreté, ciblés par le programme fédéral EPA 2023.

→ **Action** : Mise en avant des subventions, accompagnement administratif.

Grands districts en opération

operating + large_district + high_need

Grands districts ayant déjà des bus électriques en opération, à forts besoins scolaires.

→ **Action** : Extension de flotte, services premium et maintenance.

Aisés urbains

high_income + urban (souvent large_district)

Districts urbains à revenus élevés, généralement de grande taille.

→ **Action** : Offres standard, démonstration ROI et image écologique.

Charge polluante élevée

pollution_burden + epa_2023 + committed

Districts identifiés par EPA pour leur exposition à la pollution.

→ **Action** : Argument santé publique, partenariats locaux.

Conclusion & pistes

Démarche validée

- 617 itemsets fréquents extraits par Apriori (min_support = 5 %)
- 5 709 règles d'association générées (min_confidence = 40 %)
- Comparaison à Eclat : résultats identiques, choix d'Apriori validé
- 4 profils-types métier identifiés avec actions commerciales associées

Limites & pistes (B206)

- Beaucoup de règles redondantes (committed dans 100 % des transactions)
- Pas de comparaison directe entre profils engagés et non-engagés
- Piste : tester d'autres seuils support / confidence, explorer FP-Growth

Modèle retenu : Apriori (min_support = 5 %, min_confidence = 40 %)
617 itemsets · 5 709 règles · lift max 4,73 · 4 profils métier identifiés