

Lab 5 — Détection d'anomalies

Identifier les districts économiquement incohérents à l'aide de DBSCAN

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

1. Compréhension du problème métier

Objectif business

Identifier les **districts économiquement incohérents** — ceux dont le niveau d'adoption des bus électriques ne suit pas leur capacité économique.

Deux profils particulièrement intéressants pour le métier :

- Districts riches mais qui n'investissent pas → gros potentiel commercial
- Districts pauvres qui investissent quand même → références à valoriser

Question

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

Type de tâche

Détection d'anomalies

(non supervisée — on identifie les points qui s'écartent du comportement majoritaire).

Modèle imposé par le sujet : DBSCAN — algorithme de clustering basé sur la densité, capable d'étiqueter nativement les points isolés comme anomalies.

2. Compréhension des données

12 837

districts scolaires
(filtrés depuis 19 516)

3

variables socio-économiques
imposées par le sujet

~ 1 %

anomalies attendues
(taux typique en détection)

Les 3 variables utilisées

3i. % flotte électrique	Part du parc de bus déjà électrifiés
4f. Revenu médian	Capacité économique du district
4g. % pauvreté	Part de la population sous le seuil de pauvreté

Source — dataset projet ESB

On part du même fichier brut que les autres TPs (Electric School Bus Initiative, 19 516 districts). Pour le TP5, on ne garde que les 3 variables imposées par le sujet et on filtre les districts avec données complètes → 12 837 lignes, ensuite standardisées.

3. Préparation des données d'entraînement

Trois transformations appliquées en amont par l'équipe pour passer du dataset brut au fichier d'entraînement anomalies.csv.

1

Sélection des variables

On garde uniquement les 3 variables imposées par le sujet : revenu médian, % pauvreté, % flotte électrique.

2

Filtrage des districts

On ne conserve que les districts ayant les 3 variables renseignées. Résultat : 19 516 → 12 837 districts.

3

Standardisation z-score

Pour chaque variable : $(x - \text{moyenne}) \div \text{écart-type}$. Résultat final : moyenne 0, écart-type 1.

Pourquoi la standardisation est indispensable pour DBSCAN

DBSCAN repose sur des distances euclidiennes. Sans standardisation, le revenu (en milliers de dollars) écraserait totalement le % de pauvreté et le % flotte électrique (en pourcentages). **Valeurs extrêmes laissées en place :** le % flotte électrique contient des erreurs de saisie ($> 100\%$, jusqu'à $+89\sigma$). On ne les supprime pas — DBSCAN va précisément les détecter comme anomalies.

4a. L'algorithme DBSCAN

DBSCAN — Density-Based Spatial Clustering of Applications with Noise. Algorithme de clustering basé sur la densité, parfait pour la détection d'anomalies.

Principe : trois types de points (cours, ch. 4)

Point central — possède au moins $MinPts$ points dans son rayon Eps (lui-même inclus). Cœur d'un cluster.

Point frontière — n'est *pas* central, mais se trouve dans le rayon Eps d'un point central. Bord d'un cluster.

Point de bruit — n'est ni central, ni frontière : aucun point central dans son rayon Eps . Étiquette -1 → anomalie.

Méthode : on connecte les points centraux voisins en clusters, on rattache les frontières au cluster d'un central proche, et on isole les bruits.


Différences avec K-means

	K-means	DBSCAN
Nb clusters	fixé avant	déterminé automatiquement
Outliers	non gérés (force l'assignation)	étiquette -1 native
Forme clusters	sphériques	quelconques (densité)
Paramètres	K, init	eps, min_samples

→ DBSCAN est le seul à étiqueter nativement les anomalies, ce qui en fait l'algorithme de référence pour notre tâche.

4b. Choix de eps — méthode du k-distance graph

On calcule la distance au k-ième voisin de chaque point, on trie, et on cherche le « coude » : là où la densité change brusquement, on a notre eps.



Lecture du graphe

- On choisit $k = \text{min_samples} = 10$.
- Les 95 % des points ont leur 10e voisin à distance $< 0,25$.
- Le coude apparaît autour de $\text{eps} \approx 0,5$.
- Au-delà, les points sont isolés — futurs outliers.

→ **Choix : eps = 0,5**

Affiné ensuite par une grille $\text{eps} \times \text{min_samples}$.

4c. Réglage fin — grille eps × min_samples

On teste plusieurs combinaisons autour du coude. Critère : un taux d'anomalies raisonnable (typiquement entre 0,5 % et 5 %).

eps	min_samples	Outliers détectés	% outliers	Verdict
0,3	10	377	2,9 %	<i>trop sensible</i>
0,4	10	169	1,3 %	acceptable
0,5	10	108	0,8 %	★ retenu
0,7	10	52	0,4 %	acceptable
1,0	10	23	0,2 %	<i>trop conservateur</i>

Choix : eps = 0,5

- Aligné avec le coude du k-distance graph.
- 108 outliers détectés (0,8 %), proportion raisonnable.
- 1 cluster principal contenant 99,2 % des districts.

min_samples = 10

Règle empirique : $\geq 2 \times \text{dim}$ (ici $2 \times 3 = 6$, on prend 10 pour plus de robustesse).

4d. Résultats — 108 anomalies détectées

108



outliers détectés
(0,8 % du dataset)

12 729

districts dans le cluster
principal (99,2 %)

4

catégories métier
identifiées



Lecture du scatter

Points bleus : 12 729 districts du cluster principal — comportement attendu.

Points rouges : 108 anomalies isolées par DBSCAN.

On voit nettement les anomalies aux extrémités du nuage — districts atypiques sur au moins une des 3 variables.

4e. Catégorisation métier des anomalies

Les 108 outliers ne sont pas tous équivalents pour le métier — on les classe selon le sens des écarts observés.

Riches sous-investis

7 districts

Revenu élevé + % électrique faible

Districts avec capacité économique mais peu d'investissement dans la flotte électrique.

Action : forte cible commerciale — gros potentiel d'achat.

Pauvres pionniers

30 districts

Revenu faible OU pauvreté élevée + % électrique élevé

Districts défavorisés qui ont réussi à investir malgré tout — souvent grâce aux subventions.

Action : référence à mettre en avant dans la démarche commerciale.

Sur-électrifiés

17 districts

% électrique anormalement élevé ($> 5 \sigma$)

Valeurs très extrêmes, probablement erreurs de saisie dans la source ($\% > 100 \%$).

Action : à vérifier dans le pipeline de données amont.

Profils rares

54 districts

Autres combinaisons atypiques

Anomalies multidimensionnelles qui ne rentrent dans aucune des catégories ci-dessus.

Action : à analyser au cas par cas.

4f. Isolation Forest en bref

Second algorithme de détection d'anomalies, utilisé pour valider les résultats de DBSCAN. Approche radicalement différente, fondée sur des arbres aléatoires.

Principe : isoler par découpages

1. Construire de nombreux arbres aléatoires qui découpent l'espace par des coupes successives sur les variables.
2. Mesurer combien de coupes il faut pour isoler chaque point.
3. Les anomalies sont isolées en peu de coupes (elles sont « à part »), les points normaux en demandent beaucoup.

Atout : pas besoin de calculer des distances — donc plus rapide et scalable que DBSCAN sur de gros volumes.

Différences avec DBSCAN

	DBSCAN	Isolation F.
Approche	densité (voisinage)	arbres aléatoires
Distance ?	oui (euclidienne)	non
Taux à fixer ?	non (eps + min_s)	oui (contamination)
Scalabilité	moyenne	très bonne

Deux logiques opposées : la convergence des deux méthodes sur un même point renforce la fiabilité de la détection.

4g. Comparaison sur nos données

On applique les deux algorithmes aux mêmes données avec le même taux d'anomalies (~0,8 %), et on mesure leur accord par l'indice de Jaccard.

0,649

Indice de Jaccard

mesure l'accord entre 2 ensembles d'anomalies
0 = aucun accord · 1 = identique

Fort accord

Détail de la comparaison

DBSCAN : 108 anomalies détectées

IsolationF : 108 anomalies détectées

Communes aux deux : 85

Uniquement DBSCAN : 23

Uniquement IsolationF : 23

Interprétation : deux algorithmes de logiques opposées (densité vs arbres) identifient **85 anomalies communes** sur 131 anomalies au total — soit un indice de Jaccard de 0,649. Les 85 anomalies détectées par les deux méthodes sont les plus fiables.

Conclusion & pistes

Démarche validée

- k-distance graph pour calibrer eps (0,5)
- Grille eps × min_samples — 18 combinaisons testées
- 108 anomalies détectées (0,8 %, taux raisonnable)
- Validation croisée par Isolation Forest (Jaccard 0,65)

Limites & pistes

- DBSCAN sensible au choix de eps — un mauvais réglage sur/sous-détecte
- Valeurs aberrantes amont (% > 100 %) à corriger dans le pipeline
- Piste : combiner DBSCAN + Isolation Forest pour une détection robuste (intersection des résultats = 85 anomalies certaines)

Modèle retenu : DBSCAN (eps = 0,5, min_samples = 10)

108 anomalies · 4 catégories métier · 85 confirmées par Isolation Forest