

# Lab 5 — Détection d'anomalies

*Identifier les districts économiquement incohérents à l'aide de DBSCAN*

**1** Problème métier

**2** Compréhension des données

**3** Préparation

**4** Choix & réglage du modèle

# Introduction — Contexte du projet

26 M

élèves américains  
prennent le bus scolaire  
chaque matin

480 000

bus scolaires  
en circulation  
(majoritairement diesel)

19 516

districts scolaires  
recensés dans  
le dataset WRI

Ces bus circulent souvent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Depuis quelques années, des programmes fédéraux et des subventions accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

## Source de données

*Dataset of U.S. Electric School Bus Adoption*

World Resources Institute / ESB Initiative

Feuille « District-level data »

Chaque ligne = un district scolaire

91 colonnes — socio-économiques,  
environnementales, géographiques

# 1. Compréhension du problème métier

Ce TP — Détection d'anomalies par DBSCAN (non supervisé)

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

## Objectif business

Identifier les districts économiquement incohérents : ceux dont l'adoption ESB ne suit pas leur capacité économique.

- Riches sous-investis → cible commerciale
- Pauvres pionniers → références à valoriser

## Type de tâche

Détection d'anomalies — non supervisée.  
Pas de label à l'entraînement.  
Modèle imposé : DBSCAN.  
12 837 districts — 3 variables (z-scores).

## Intérêt métier

Prioriser les districts riches sous-investis (gros potentiel d'achat) et valoriser les pionniers comme références dans la démarche commerciale.

**DBSCAN** : seul algorithme à étiqueter nativement les anomalies (label -1). Les points trop isolés deviennent directement des outliers — sans les forcer dans un groupe comme K-means.

# 1. Compréhension du problème métier

## Objectif business

Identifier les **districts économiquement incohérents** — ceux dont le niveau d'adoption des bus électriques ne suit pas leur capacité économique.

**Deux profils particulièrement intéressants pour le métier :**

- Districts riches mais qui n'investissent pas → gros potentiel commercial
- Districts pauvres qui investissent quand même → références à valoriser

## Question

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

## Type de tâche

### Détection d'anomalies

(non supervisée — on identifie les points qui s'écartent du comportement majoritaire).

**Modèle imposé par le sujet :** DBSCAN — algorithme de clustering basé sur la densité, capable d'étiqueter nativement les points isolés comme anomalies.

## 2. Compréhension des données

12 837

districts scolaires  
(filtrés depuis 19 516)

3

variables socio-économiques  
imposées par le sujet

~ 1 %

anomalies attendues  
(taux typique en détection)

### Les 3 variables utilisées

|                         |                                                 |
|-------------------------|-------------------------------------------------|
| 3i. % flotte électrique | Part du parc de bus déjà électrifiés            |
| 4f. Revenu médian       | Capacité économique du district                 |
| 4g. % pauvreté          | Part de la population sous le seuil de pauvreté |

### Source — dataset projet ESB

On part du même fichier brut que les autres TP (Electric School Bus Initiative, 19 516 districts). Pour le TP5, on ne garde que les 3 variables imposées par le sujet et on filtre les districts avec données complètes → 12 837 lignes, ensuite standardisées.

# 3. Préparation des données d'entraînement

Trois transformations appliquées en amont par l'équipe pour passer du dataset brut au fichier d'entraînement anomalies.csv.

1

## Sélection des variables

On garde uniquement les 3 variables imposées par le sujet : revenu médian, % pauvreté, % flotte électrique.

2

## Filtrage des districts

On ne conserve que les districts ayant les 3 variables renseignées. Résultat : 19 516 → 12 837 districts.

3

## Standardisation z-score

Pour chaque variable :  $(x - \text{moyenne}) \div \text{écart-type}$ . Résultat final : moyenne 0, écart-type 1.

## Pourquoi la standardisation est indispensable pour DBSCAN

DBSCAN repose sur des distances euclidiennes. Sans standardisation, le revenu (en milliers de dollars) écraserait totalement le % de pauvreté et le % flotte électrique (en pourcentages). **Valeurs extrêmes laissées en place :** le % flotte électrique contient des erreurs de saisie ( $> 100\%$ , jusqu'à  $+89\sigma$ ). On ne les supprime pas — DBSCAN va précisément les détecter comme anomalies.

# 4a. L'algorithme DBSCAN

DBSCAN — Density-Based Spatial Clustering of Applications with Noise. Algorithme de clustering basé sur la densité, parfait pour la détection d'anomalies.

## Principe : trois types de points (cours, ch. 4)

**Point central** — possède au moins `MinPts` points dans son rayon `Eps` (lui-même inclus). Cœur d'un cluster.

**Point frontière** — n'est pas central, mais se trouve dans le rayon `Eps` d'un point central. Bord d'un cluster.

**Point de bruit** — n'est ni central, ni frontière : aucun point central dans son rayon `Eps`. Étiquette -1 → anomalie.

**Méthode** : on connecte les points centraux voisins en clusters, on rattache les frontières au cluster d'un central proche, et on isole les bruits.


## Différences avec K-means

|                | K-means                         | DBSCAN                    |
|----------------|---------------------------------|---------------------------|
| Nb clusters    | fixé avant                      | déterminé automatiquement |
| Outliers       | non gérés (force l'assignation) | étiquette -1 native       |
| Forme clusters | sphériques                      | quelconques (densité)     |
| Paramètres     | K, init                         | eps, min_samples          |

→ DBSCAN est le seul à étiqueter nativement les anomalies, ce qui en fait l'algorithme de référence pour notre tâche.

## 4b. Choix de eps — méthode du k-distance graph

On calcule la distance au k-ième voisin de chaque point, on trie, et on cherche le « coude » : là où la densité change brusquement, on a notre eps.



### Lecture du graphe

- On choisit  $k = \text{min\_samples} = 10$ .
- Les 95 % des points ont leur 10e voisin à distance  $< 0,25$ .
- Le coude apparaît autour de  $\text{eps} \approx 0,5$ .
- Au-delà, les points sont isolés — futurs outliers.

→ Choix :  $\text{eps} = 0,5$

Affiné ensuite par une grille  $\text{eps} \times \text{min\_samples}$ .



## 4c. Réglage fin — grille eps × min\_samples

On teste plusieurs combinaisons autour du coude. Critère : un taux d'anomalies raisonnable (typiquement entre 0,5 % et 5 %).

| eps        | min_samples | Outliers détectés | % outliers   | Verdict                  |
|------------|-------------|-------------------|--------------|--------------------------|
| 0,3        | 10          | 377               | 2,9 %        | <i>trop sensible</i>     |
| 0,4        | 10          | 169               | 1,3 %        | acceptable               |
| <b>0,5</b> | <b>10</b>   | <b>108</b>        | <b>0,8 %</b> | <b>★ retenu</b>          |
| 0,7        | 10          | 52                | 0,4 %        | acceptable               |
| 1,0        | 10          | 23                | 0,2 %        | <i>trop conservateur</i> |

### Choix : eps = 0,5

- Aligné avec le coude du k-distance graph.
- 108 outliers détectés (0,8 %), proportion raisonnable.
- 1 cluster principal contenant 99,2 % des districts.

**min\_samples = 10**

Règle empirique :  $\geq 2 \times \text{dim}$  (ici  $2 \times 3 = 6$ , on prend 10 pour plus de robustesse).

## 4d. Résultats — 108 anomalies détectées

108



outliers détectés  
(0,8 % du dataset)

12 729

districts dans le cluster  
principal (99,2 %)

4

catégories métier  
identifiées



### Lecture du scatter

Points bleus : 12 729 districts du cluster principal — comportement attendu.

Points rouges : 108 anomalies isolées par DBSCAN.

On voit nettement les anomalies aux extrémités du nuage — districts atypiques sur au moins une des 3 variables.

## 4e. Catégorisation métier des anomalies

Les 108 outliers ne sont pas tous équivalents pour le métier — on les classe selon le sens des écarts observés.

### Riches sous-investis

7 districts

*Revenu élevé + % électrique faible*

Districts avec capacité économique mais peu d'investissement dans la flotte électrique.

---

Action : forte cible commerciale — gros potentiel d'achat.

### Pauvres pionniers

30 districts

*Revenu faible OU pauvreté élevée + % électrique élevé*

Districts défavorisés qui ont réussi à investir malgré tout — souvent grâce aux subventions.

---

Action : référence à mettre en avant dans la démarche commerciale.

### Sur-électrifiés

17 districts

*% électrique anormalement élevé ( $> 5 \sigma$ )*

Valeurs très extrêmes, probablement erreurs de saisie dans la source ( $\% > 100 \%$ ).

---

Action : à vérifier dans le pipeline de données amont.

### Profils rares

54 districts

*Autres combinaisons atypiques*

Anomalies multidimensionnelles qui ne rentrent dans aucune des catégories ci-dessus.

---

Action : à analyser au cas par cas.

## 4f. Isolation Forest en bref

Second algorithme de détection d'anomalies, utilisé pour valider les résultats de DBSCAN. Approche radicalement différente, fondée sur des arbres aléatoires.

### Principe : isoler par découpages

1. Construire de nombreux arbres aléatoires qui découpent l'espace par des coupes successives sur les variables.
2. Mesurer combien de coupes il faut pour isoler chaque point.
3. Les anomalies sont isolées en peu de coupes (elles sont « à part »), les points normaux en demandent beaucoup.

---

**Atout :** pas besoin de calculer des distances — donc plus rapide et scalable que DBSCAN sur de gros volumes.

### Différences avec DBSCAN

|                | DBSCAN              | Isolation F.        |
|----------------|---------------------|---------------------|
| Approche       | densité (voisinage) | arbres aléatoires   |
| Distance ?     | oui (euclidienne)   | non                 |
| Taux à fixer ? | non (eps + min_s)   | oui (contamination) |
| Scalabilité    | moyenne             | très bonne          |

Deux logiques opposées : la convergence des deux méthodes sur un même point renforce la fiabilité de la détection.

## 4g. Comparaison sur nos données

On applique les deux algorithmes aux mêmes données avec le même taux d'anomalies (~0,8 %), et on mesure leur accord par l'indice de Jaccard.

# 0,649

### Indice de Jaccard

mesure l'accord entre 2 ensembles d'anomalies  
0 = aucun accord · 1 = identique

*Fort accord*

### Détail de la comparaison

**DBSCAN** : 108 anomalies détectées

**IsolationF** : 108 anomalies détectées

**Communes aux deux** : 85

Uniquement DBSCAN : 23

Uniquement IsolationF : 23

**Interprétation** : deux algorithmes de logiques opposées (densité vs arbres) identifient **85 anomalies communes** sur 131 anomalies au total — soit un indice de Jaccard de 0,649. Les 85 anomalies détectées par les deux méthodes sont les plus fiables.

# Conclusion & pistes

## Démarche validée

- k-distance graph pour calibrer eps (0,5)
- Grille eps × min\_samples — 18 combinaisons testées
- 108 anomalies détectées (0,8 %, taux raisonnable)
- Validation croisée par Isolation Forest (Jaccard 0,65)

## Limites & pistes

- DBSCAN sensible au choix de eps — un mauvais réglage sur/sous-détecte
- Valeurs aberrantes amont (% > 100 %) à corriger dans le pipeline
- Piste : combiner DBSCAN + Isolation Forest pour une détection robuste (intersection des résultats = 85 anomalies certaines)

**Modèle retenu : DBSCAN (eps = 0,5, min\_samples = 10)**

108 anomalies · 4 catégories métier · 85 confirmées par Isolation Forest