

Machine Learning II — ADIF84

Lab 5 — Détection d'anomalies

Identifier les districts économiquement incohérents à l'aide de DBSCAN

1 Problème métier

2 Compréhension des données

3 Préparation

4 Choix & réglage du modèle

Modèle imposé par le sujet : DBSCAN — clustering basé sur la densité

Introduction — Contexte du projet

26 M

élèves américains
prennent le bus scolaire
chaque matin

480 000

bus scolaires
en circulation
(majoritairement diesel)

19 516

districts scolaires
recensés dans
le dataset WRI

Ces bus circulent dans les quartiers les plus exposés à la pollution — **une question d'équité autant que de santé publique.**

Des programmes fédéraux accélèrent la transition électrique. Mais sur 19 516 districts, la grande majorité n'a pas encore franchi le pas.

Notre projet : utiliser le **machine learning** pour comprendre, anticiper et accélérer cette transition.

Source de données

Dataset of U.S. Electric School Bus Adoption
World Resources Institute / ESB Initiative

Feuille « District-level data »
Chaque ligne = un district scolaire
91 colonnes — socio-éco, environnementales,
géographiques

1. Compréhension du problème métier

Ce TP — Détection d'anomalies par DBSCAN (non supervisé)

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

Objectif business

Identifier les districts économiquement incohérents : ceux dont l'adoption ESB ne suit pas leur capacité économique.
— Riches sous-investis → cible commerciale
— Pauvres pionniers → références à valoriser

Type de tâche

Détection d'anomalies — non supervisée.
Pas de label à l'entraînement.
Modèle imposé : DBSCAN.
12 837 districts, 3 variables (z-scores).

Intérêt métier

Prioriser les districts riches sous-investis (gros potentiel d'achat) et valoriser les pionniers comme références.

DBSCAN : seul algorithme à étiqueter nativement les anomalies (label -1). Les points isolés deviennent directement des outliers — sans forcer

1. Compréhension du problème métier

Objectif business

Identifier les **districts économiquement incohérents** — ceux dont le niveau d'adoption des bus électriques ne suit pas leur capacité économique.

Deux profils particulièrement intéressants pour le métier :

- Districts riches mais qui n'investissent pas → gros potentiel commercial
- Districts pauvres qui investissent quand même → références à valoriser

Question à laquelle le modèle répond :

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

Question

« Quels districts se comportent de manière atypique par rapport à la corrélation attendue entre richesse et électrification ? »

Type de tâche

Détection d'anomalies

(non supervisée — on identifie les points qui s'écartent du comportement majoritaire).

Modèle : **DBSCAN** — clustering basé sur la densité, étiquette nativement les points isolés comme anomalies.

2. Compréhension des données

12 837

districts scolaires

3

variables socio-économiques
(z-scores standardisés)

~ 1 %

anomalies attendues
(taux typique en détection)

Les 3 variables utilisées

3i. % flotte électrique

Part du parc de bus déjà électrifiés

4f. Revenu médian

Capacité économique du district

4g. % pauvreté

Part de la population sous le seuil de pauvreté

Données déjà préparées (z-scores standardisés)

Les 3 variables sont centrées-réduites : moyenne = 0, écart-type = 1. Cette standardisation est indispensable pour DBSCAN, qui repose sur des distances euclidiennes : sans elle, la variable au plus grand écart-type écraserait les autres.

3. Préparation des données d'entraînement

Étape unique : standardisation (déjà appliquée en amont)

Le jeu **anomalies.csv** est livré **déjà standardisé** : moyenne = 0, écart-type = 1 pour chacune des 3 variables.

Pourquoi indispensable pour DBSCAN : l'algorithme calcule des distances euclidiennes. Sans standardisation, le revenu (en milliers) écraserait totalement les pourcentages. Aucune autre transformation n'est nécessaire.

Note sur les valeurs extrêmes

Le « % flotte électrique » contient des valeurs jusqu'à $+89 \sigma$. Ce sont des erreurs de saisie ($\% > 100 \%$). *Choix : on ne les supprime pas — DBSCAN va naturellement les détecter comme anomalies, c'est précisément ce qu'on cherche.*

Le jeu **anomalies.csv** (40 007 lignes, 3 variables) — fichier d'entraînement demandé pour la partie 1

4a. L'algorithme DBSCAN

DBSCAN — Density-Based Spatial Clustering of Applications with Noise.

Principe : trois types de points (cours, ch. 4)

Point central

— possède au moins MinPts points dans son rayon Eps. Cœur d'un cluster.

Point frontière

— n'est pas central, mais dans le rayon Eps d'un point central. Bord d'un cluster.

Point de bruit

— n'est ni central, ni frontière : aucun point central dans son rayon Eps. Étiquette -1 → anomalie.

Méthode : on connecte les centraux voisins en clusters, on rattache les frontières, et on isole les bruits.

Différences avec K-means


	K-means	DBSCAN
Nb clusters	fixé avant	automatique
Outliers	forcé	étiquette -1
Clusters	sphériques	quelconques
Paramètres	K, init	eps, min_s

→ DBSCAN est le seul à étiqueter nativement les anomalies, ce qui en fait l'algorithme de référence pour notre tâche.

4b. Choix de eps — méthode du k-distance graph

On calcule la distance au k-ième voisin, on trie, et on cherche le « coude » : là où la densité change brusquement.

K-distance graph (k = 10)



Lecture du graphe

On choisit $k = \text{min_samples} = 10$.

95 % des points : 10e voisin à distance $< 0,25$.

Le coude apparaît autour de $\text{eps} \approx 0,5$.

Au-delà : points isolés — futurs outliers.

→ **Choix : $\text{eps} = 0,5$**

Affiné ensuite par une grille $\text{eps} \times \text{min_samples}$.

4c. Réglage fin — grille eps × min_samples

On teste plusieurs combinaisons au tour du coude. Critère : taux d'anomalies entre 0,5 % et 5 %.

eps	min_samples	Outliers	% outliers	Verdict
0,3	10	377	2,9 %	trop sensible
0,4	10	169	1,3 %	acceptable
0,5	10	108	0,8 %	★ retenu
0,7	10	52	0,4 %	acceptable
1,0	10	23	0,2 %	trop conservateur

Choix : eps = 0,5

Aligné avec le coude du k-distance graph.

108 outliers (0,8 %), proportion raisonnable.

1 cluster principal : 99,2 % des districts.

min_samples = 10

Règle : $\geq 2 \times \text{dim}$ (ici $2 \times 3 = 6$, on prend 10 pour plus de robustesse).

4d. Résultats — 108 anomalies détectées

108

outliers détectés
(0,8 % du dataset)

12 729

districts dans le cluster
principal (99,2 %)

4

catégories métier
identifiées

Projection des résultats DBSCAN

- 12 729 districts normaux (cluster principal)
- 108 anomalies DBSCAN (label = -1)

Les anomalies apparaissent aux extrémités du nuage — districts atypiques sur au moins une des 3 variables.

Lecture du scatter

Points bleus : 12 729 districts — comportement attendu.

Points rouges : 108 anomalies isolées par DBSCAN.

Districts atypiques sur au moins une des 3 variables.

4e. Catégorisation métier des anomalies

Les 108 outliers ne sont pas tous équivalents — on les classe selon le sens des écarts observés.

Riches sous-investis

7 districts

Revenu élevé + % électrique faible

Districts avec capacité économique mais peu d'investissement dans la flotte électrique.

Action : forte cible commerciale — gros potentiel d'achat.

Pauvres pionniers

30 districts

Revenu faible OU pauvreté élevée + % électrique élevé

Districts défavorisés qui ont réussi à investir malgré tout — souvent grâce aux subventions.

Action : référence à mettre en avant dans la démarche commerciale.

Sur-électrifiés

17 districts

% électrique anormalement élevé ($> 5 \sigma$)

Valeurs très extrêmes, probablement erreurs de saisie dans la source ($\% > 100 \%$).

Action : à vérifier dans le pipeline de données amont.

Profils rares

54 districts

Autres combinaisons atypiques

Anomalies multidimensionnelles qui ne rentrent dans aucune des catégories ci-dessus.

Action : à analyser au cas par cas.

4f. Isolation Forest en bref

Second algorithme de détection d'anomalies, utilisé pour valider les résultats de DBSCAN.

Principe : isoler par découpages

1. Construire de nombreux arbres aléatoires qui découpent l'espace par des coupes successives sur les variables.
2. Mesurer combien de coupes il faut pour isoler chaque point.
3. Les anomalies sont isolées en peu de coupes (elles sont « à part »), les points normaux en demandent beaucoup.

Atout : pas de calcul de distances — plus rapide et scalable que DBSCAN sur de gros volumes.

Différences avec DBSCAN

	DBSCAN	Isolation F.
Approche	densité (voisinage)	arbres aléatoires
Distance ?	oui (euclidienne)	non
Taux à fixer ?	non (eps+min_s)	oui (contamination)
Scalabilité	moyenne	très bonne

Deux logiques opposées : la convergence des deux méthodes sur un même point renforce la fiabilité de la détection.

4g. Comparaison sur nos données

On applique les deux algorithmes aux mêmes données (~0,8 %) et on mesure leur accord par l'indice de Jaccard.

0,649

Indice de Jaccard

mesure l'accord entre 2 ensembles
0 = aucun accord · 1 = identique

Fort accord

Détail de la comparaison

DBSCAN : 108 anomalies détectées

IsolationF : 108 anomalies détectées

Communes aux deux : 85

Uniquement DBSCAN : 23

Uniquement IsolationF : 23

Interprétation : deux logiques opposées identifient **85 anomalies communes** sur 131 au total (Jaccard = 0,649). Ces 85 sont les plus fiables.

Conclusion & pistes

Démarche validée

k-distance graph pour calibrer eps (0,5)

Grille eps × min_samples — 18 combinaisons testées

108 anomalies détectées (0,8 %, taux raisonnable)

Validation croisée par Isolation Forest (Jaccard 0,65)

Limites & pistes

DBSCAN sensible au choix de eps — un mauvais réglage sur/sous-détecte.

Valeurs aberrantes amont (% > 100 %) à corriger dans le pipeline.

Piste : combiner DBSCAN + Isolation Forest (85 anomalies communes = résultat le plus fiable).

Modèle retenu : **DBSCAN (eps = 0,5, min_samples = 10)**

108 anomalies • 4 catégories métier • 85 confirmées par Isolation Forest